



Grado en Ingeniería Matemática e Inteligencia Artificial (iMAT)

MÉTODOS NUMÉRICOS

Proyecto

Métodos tipo Monte Carlo

2.º iMAT B — Grupo 4

Curso 2025 – 2026

Integrantes

Javier Martínez Montelongo —

Ignacio Mascarell Agúndez —

Juan Tabuyo Castell —

Jaime Tuesta de Simón —

Yago Vallarino Fernández-Cavada —

Índice

1	Introducción	1
2	Integración como valor esperado	2
2.1	Descripción	2
2.2	Implementación	2
2.3	Observaciones	2
3	Variabilidad del método	3
3.1	Descripción	3
3.2	Variabilidad entre ejecuciones	3
3.3	Media y varianza muestral	3
3.4	Observaciones	4
4	Convergencia del método	5
4.1	Descripción	5
4.2	Error en función del número de muestras	5
4.3	Estimación del orden de convergencia	6
4.4	Observaciones	6
5	Método de aceptación–rechazo	7
5.1	Descripción	7
5.2	Implementación	7
5.3	Observaciones	7
6	Importance sampling	8
6.1	Motivación	8
6.2	Método	9
6.3	Implementación	10
6.4	Observaciones	11
7	Comparación con métodos deterministas	13
7.1	Descripción	13
7.2	Resultados	13
7.3	Observaciones	14
8	Integración en dimensión superior	15
8.1	Descripción	15
8.2	Monte Carlo en dos dimensiones	15
8.3	Comparación con métodos deterministas en 2D	16
8.4	Dimensión alta	18
9	Aplicación: valoración de opciones financieras	20
9.1	Introducción	20
9.2	Estimación Monte Carlo y validación	20
9.3	Convergencia	20
9.4	Reducción de varianza mediante <i>importance sampling</i>	21
9.5	Observaciones	21
10	Conclusiones	22

1. Introducción

La integración numérica tiene como objetivo aproximar el valor de una integral definida mediante un número finito de evaluaciones de la función integrando. Cuando no es posible calcular la integral de forma analítica, resulta imprescindible recurrir a métodos numéricos que proporcionen una estimación suficientemente precisa.

En los temas previos del curso se han estudiado métodos de tipo determinista, como las fórmulas de Newton–Côtes o las cuadraturas de Gauss. Estos métodos construyen la aproximación a partir de una selección fija y estructurada de puntos de evaluación y presentan una convergencia rápida en problemas de baja dimensión.

Existe, sin embargo, un enfoque alternativo basado en el uso de variables aleatorias. Los llamados **métodos tipo Monte Carlo** aproximan integrales mediante muestreo aleatorio, interpretando la integral como una esperanza matemática. Su convergencia es más lenta, del orden $\mathcal{O}(n^{-1/2})$, pero presentan una ventaja fundamental: su coste computacional no crece exponencialmente con la dimensión, a diferencia de los métodos basados en mallas regulares. Esto los hace imprescindibles en áreas como el *Machine Learning* o la simulación de sistemas complejos.

El objetivo del presente proyecto es estudiar distintos métodos tipo Monte Carlo para aproximar integrales, analizar su variabilidad y su convergencia, explorar técnicas de reducción de varianza como el *importance sampling* y comparar su comportamiento con el de métodos deterministas clásicos. Como cierre, se incluye una aplicación práctica en finanzas cuantitativas: la valoración de una opción *call* europea.

2. Integración como valor esperado

2.1. Descripción

Sea $f : [a, b] \rightarrow \mathbb{R}$ una función integrable y sea X una variable aleatoria uniforme en $[a, b]$. Entonces se cumple la identidad

$$\int_a^b f(x) dx = (b - a) \mathbb{E}[f(X)], \quad (1)$$

lo que sugiere aproximar la integral mediante la media de evaluaciones de la función en puntos aleatorios. Sustituyendo la esperanza por la media muestral se obtiene el estimador

$$I_n = \frac{b - a}{n} \sum_{i=1}^n f(x_i) \approx \int_a^b f(x) dx, \quad (2)$$

donde los puntos $x_1, \dots, x_n$ se generan de forma aleatoria y uniforme en $[a, b]$.

2.2. Implementación

Se implementa en Python el estimador descrito y se aplica a tres funciones de prueba cuyo valor exacto es conocido, empleando $n = 10\,000$ muestras. Los resultados se recogen en la Tabla 1.

Tabla 1. Aproximación Monte Carlo uniforme para tres funciones de prueba ($n = 10\,000$).

Función	Intervalo	Valor exacto	Aprox. I_n	Error abs.
x^2	$[0, 1]$	0,33333	0,33459	0,00126
$\text{sen}(x)$	$[0, \pi]$	2,00000	1,99862	0,01380
e^x	$[0, 1]$	1,71828	1,71559	0,00270

2.3. Observaciones

Los errores obtenidos son pequeños, del orden de 10^{-2} para $n = 10\,000$. No obstante, el resultado varía ligeramente en cada ejecución debido a la naturaleza estocástica del método; este comportamiento se analiza en detalle en la siguiente sección.

3. Variabilidad del método

3.1. Descripción

A diferencia de los métodos deterministas, la salida de un algoritmo Monte Carlo depende de los números aleatorios generados, por lo que dos ejecuciones con el mismo número de muestras pueden producir resultados distintos. Es conveniente, por tanto, interpretar la salida del método como una variable aleatoria y estudiar su media y su varianza.

3.2. Variabilidad entre ejecuciones

Se realizan diez ejecuciones independientes del método para aproximar la integral de $f(x) = x^2$ en $[0, 1]$ con $n = 10\,000$ muestras; los resultados se recogen en la Tabla 2.

Tabla 2. Diez ejecuciones independientes del método Monte Carlo uniforme ($f(x) = x^2$, $n = 10\,000$).

Ejecución	Aproximación I_n
1	0,33608875122824705
2	0,33291329937305797
3	0,32322306667492223
4	0,33095106546482790
5	0,33229632058865627
6	0,33195996348662490
7	0,33196825098805366
8	0,33564038863928890
9	0,33435149885215870
10	0,33514023788264896

Media muestral: **0,33245**. Varianza muestral: **$1,35962 \cdot 10^{-5}$** .

3.3. Media y varianza muestral

La media y la varianza muestral insesgada se definen como

$$\bar{I} = \frac{1}{m} \sum_{j=1}^m I_n^{(j)}, \quad S^2 = \frac{1}{m-1} \sum_{j=1}^m (I_n^{(j)} - \bar{I})^2, \quad (3)$$

donde el denominador $m - 1$ garantiza que S^2 sea un estimador insesgado de la varianza. A medida que n crece, la media debe converger al valor exacto y la varianza debe tender a cero. Con $m = 50$ repeticiones para cada valor de n se obtienen los resultados de la Tabla 3.

Tabla 3. Media y varianza muestrales de 50 ejecuciones del método uniforme ($f(x) = x^2$).

n	Media	Varianza
100	0,33748	$9,5088 \cdot 10^{-4}$
1 000	0,33494	$9,4920 \cdot 10^{-5}$
10 000	0,33365	$1,0420 \cdot 10^{-5}$
100 000	0,33324	$7,1000 \cdot 10^{-7}$

3.4. Observaciones

Para un n fijo, las aproximaciones son distintas entre ejecuciones, pero una varianza baja basta para justificar la validez del método. Al iterar sobre distintos valores de n se aprecia que la media converge al valor exacto y que la varianza decrece aproximadamente como $1/n$: multiplicar n por 10 divide la varianza por un factor próximo a 10. Este comportamiento es compatible con el error típico de orden $\mathcal{O}(n^{-1/2})$.

4. Convergencia del método

4.1. Descripción

Por la ley de los grandes números, el estimador I_n converge al valor exacto de la integral cuando $n \rightarrow \infty$. El teorema central del límite garantiza además que el error típico decrece como $1/\sqrt{n}$, es decir, que el método Monte Carlo tiene orden de convergencia $\mathcal{O}(n^{-1/2})$. En esta sección se verifica esta afirmación de forma experimental.

4.2. Error en función del número de muestras

Se aproxima el valor de π mediante la integral

$$\pi = \int_0^1 4\sqrt{1-x^2} dx, \quad (4)$$

para distintos valores de n . La Tabla 4 recoge las aproximaciones obtenidas y sus respectivos errores.

Tabla 4. Aproximación de π mediante Monte Carlo uniforme para distintos valores de n .

n	Aproximación	Error absoluto	Error relativo
10	3,0904514263	0,051141	1,6279 %
50	3,1349424993	0,006650	0,2117 %
100	3,1210168195	0,020576	0,6549 %
500	3,1416890809	0,000096	0,0031 %
1 000	3,1433515512	0,001759	0,0560 %
5 000	3,1417590255	0,000166	0,0053 %
10 000	3,1409550090	0,000638	0,0203 %
50 000	3,1414777870	0,000115	0,0037 %
100 000	3,1418680643	0,000275	0,0088 %
500 000	3,1419148842	0,000322	0,0103 %
1 000 000	3,1415544320	0,000038	0,0012 %
5 000 000	3,1415369371	0,000056	0,0018 %

Representando el error en escala logarítmica frente al número de muestras, los puntos se alinean de forma aproximada con una recta de pendiente $-1/2$, como muestra la Figura 1.




Figura 1. Error de aproximación de la integral en función del número de muestras n (escala log-log). La línea discontinua representa la referencia teórica $O(n^{-1/2})$.

4.3. Estimación del orden de convergencia

El orden de convergencia se estima ajustando una recta a los puntos $(\log n, \log |\text{error}|)$. La pendiente de dicha recta coincide con el exponente del orden. Calculando la pendiente media sobre 11 intervalos consecutivos se obtiene un valor de $-0,481$, muy próximo al valor teórico esperado de $-0,5$.

4.4. Observaciones

Los resultados son consistentes con las hipótesis teóricas. La tendencia del error es muy similar a la recta de pendiente $-1/2$, con oscilaciones atribuibles al carácter estocástico del método, pese a haber promediado varias ejecuciones. La estimación directa de la pendiente confirma adicionalmente el orden de convergencia.

5. Método de aceptación–rechazo

5.1. Descripción

Sea $f : [a, b] \rightarrow \mathbb{R}$ una función **no negativa**, y sea M una cota superior tal que $0 \leq f(x) \leq M$ para todo $x \in [a, b]$. La integral puede interpretarse entonces como el área de la región bajo la curva, contenida en el rectángulo $[a, b] \times [0, M]$. Si se generan n puntos aleatorios uniformes en dicho rectángulo y una proporción p de ellos cae bajo la gráfica, se tiene

$$\int_a^b f(x) \, dx \approx p \cdot (b - a) \cdot M, \quad (5)$$

donde un punto (x_i, y_i) se acepta si cumple $y_i \leq f(x_i)$ y se rechaza en caso contrario. La proporción p se estima mediante el cociente entre propuestas aceptadas y propuestas totales.

5.2. Implementación

Se generan puntos aleatorios en el rectángulo $[a, b] \times [0, M]$ para las tres funciones analizadas en la sección 2¹ y se comparan los resultados con los obtenidos mediante el método uniforme, recogidos en la Tabla 5.

Tabla 5. Comparación entre el método Monte Carlo uniforme y el método de aceptación–rechazo.

Función	Intervalo	Valor exacto	MC uniforme	Ac.–rechazo
x^2	$[0, 1]$	0,33333	0,33459	0,33090
$\text{sen}(x)$	$[0, \pi]$	2,00000	1,99862	2,00371
e^x	$[0, 1]$	1,71828	1,71559	1,71937

5.3. Observaciones

Los resultados del método de aceptación–rechazo son comparables a los del método uniforme. Su eficiencia depende crucialmente de lo ajustada que esté la cota M : si M es mucho mayor que el máximo real de f , la proporción de puntos aceptados es pequeña y el método se vuelve ineficiente.

¹Nótese que los valores de la columna “MC uniforme” corresponden a las mismas ejecuciones que en la Tabla 1.

6. Importance sampling

6.1. Motivación

El método Monte Carlo uniforme resulta ineficiente cuando la función integrando presenta picos estrechos y pronunciados. En tales situaciones, la mayor parte del valor de la integral proviene de regiones muy pequeñas del dominio, de manera que la mayoría de los puntos generados uniformemente caen en zonas donde la función toma valores despreciables. El resultado es una aproximación muy pobre, incluso con un número elevado de muestras.

Como ilustración, se aproxima la integral en $[-1, 1]$ de una gaussiana concentrada, con pico muy pronunciado en $x = 0$. La aproximación obtenida es 0,12856, siendo el valor exacto 0,12533. La integral sobre $\mathbb{R}$ coincide con $\sigma\sqrt{2\pi} = 0,12533$, y la diferencia con la integral sobre $[-1, 1]$ es despreciable, ya que la función está concentrada en torno al origen.




Figura 2. Gaussiana concentrada: los puntos Monte Carlo uniformes (en rojo) caen mayoritariamente fuera de la región donde se concentra el área (en verde).

Se observa que la mayoría de los puntos caen fuera del pico, reflejo de la ineficiencia del muestreo uniforme. Repitiendo el experimento para diferentes valores de n , promediando 30 ejecuciones para reducir el ruido, se obtienen los resultados de la Tabla 6 y la Figura 3.

Tabla 6. Monte Carlo uniforme sobre una gaussiana concentrada: aproximación media y error medio sobre 30 ejecuciones.

n	Aproximación media	Error medio
10	0,184193	0,128285
50	0,115589	0,040662
100	0,120340	0,031758
500	0,118448	0,013233
1 000	0,124880	0,009271
5 000	0,126701	0,005092
10 000	0,124362	0,003626
50 000	0,125886	0,001379
100 000	0,125489	0,001002
500 000	0,125313	0,000284
1 000 000	0,125386	0,000325
5 000 000	0,125295	0,000174




Figura 3. Convergencia del método Monte Carlo uniforme para una gaussiana concentrada: media de 30 ejecuciones frente al valor exacto.

Para valores pequeños de n , el error es muy elevado; sólo cuando n crece notablemente la aproximación comienza a estabilizarse. Esto confirma que el método uniforme es muy ineficiente para funciones con picos.

6.2. Método

Sea $\rho(x)$ una densidad de probabilidad estrictamente positiva en $[a, b]$. La integral puede reescribirse como

$$\int_a^b f(x) \, dx = \int_a^b \frac{f(x)}{\rho(x)} \rho(x) \, dx \approx \frac{1}{n} \sum_{i=1}^n \frac{f(x_i)}{\rho(x_i)}, \quad (6)$$

donde los puntos x_i se generan ahora según la densidad ρ . La idea es concentrar las muestras donde f toma valores grandes eligiendo una densidad ρ que se parezca a f (salvo constante de normalización).

6.3. Implementación

En primer lugar, se aplica el método a $f(x) = x^2$ en $[0, 1]$ utilizando la densidad $\rho(x) = 2x$, que integra 1 en el intervalo y concentra masa hacia $x = 1$. La aproximación obtenida es 0,33371 (exacto: 0,33333; error: 0,00038).

A continuación, se compara el comportamiento del método uniforme y del *importance sampling* para la gaussiana concentrada anterior, empleando como ρ una gaussiana proporcional a f . Los resultados se muestran en la Tabla 7 y la Figura 4.

Tabla 7. Comparación entre Monte Carlo uniforme e importance sampling con $\rho \propto f$ para la gaussiana concentrada.

n	MC uniforme	Error uniforme	Imp. Sampling	Error IS
10	0,158496	0,098885	0,125331	≈ 0
50	0,143777	0,054119	0,125331	≈ 0
100	0,106176	0,035701	0,125331	≈ 0
500	0,125965	0,013703	0,125331	≈ 0
1 000	0,123728	0,009033	0,125331	≈ 0
5 000	0,125205	0,004202	0,125331	≈ 0
10 000	0,125590	0,003299	0,125331	≈ 0
50 000	0,125257	0,001264	0,125331	≈ 0
100 000	0,125488	0,000883	0,125331	≈ 0
500 000	0,125250	0,000488	0,125331	≈ 0




Figura 4. Comparación log-log de MC uniforme e importance sampling para una función con pico. Cuando $\rho \propto f$, el error del IS es prácticamente nulo.

Se considera ahora la función $f(x) = 1/(1+x^6)$ en $[-3, 3]$, empleando como ρ una gaussiana $\mathcal{N}(0, \sigma^2)$ truncada al intervalo, con $\sigma^2 \in \{0,25; 1,0; 2,25; 4,0; 9,0\}$. El error medio se calcula sobre 30 ejecuciones con $n = 100\,000$ y se compara con el método uniforme.

Valor exacto (cuadratura adaptativa): **2,09275004**.

MC uniforme (30 ejecuciones): 2,093623, con error medio 0,005107.

Tabla 8. Importance sampling con distintas varianzas frente a MC uniforme para $f(x) = 1/(1+x^6)$ en $[-3, 3]$.

σ^2	σ	Aproximación IS	Error IS	Error MC uniforme
0,25	0,50	2,089659	0,006527	0,005107
1,00	1,00	2,091522	0,002427	0,005107
2,25	1,50	2,092824	0,002821	0,005107
4,00	2,00	2,093237	0,004107	0,005107
9,00	3,00	2,092351	0,005153	0,005107




Figura 5. Error medio del importance sampling para distintas varianzas de la gaussiana propuesta, comparado con la línea de referencia del MC uniforme.

La gaussiana con $\sigma^2 \approx 1$ ofrece los mejores resultados, ya que se adapta bien a la forma de f , que concentra la mayor parte de su área en torno al origen pero con colas moderadas. Una σ^2 demasiado pequeña concentra en exceso las muestras y desaprovecha las colas, mientras que una σ^2 demasiado grande dispersa las muestras y el método degenera hacia el comportamiento uniforme.

6.4. Observaciones

El *importance sampling* reduce drásticamente el error del método uniforme cuando la densidad propuesta se adapta a la función integrando. En el caso ideal, $\rho \propto f$, el cociente f/ρ es constante

y la varianza del estimador se anula, de modo que la estimación es exacta. Este resultado, observado empíricamente en la Tabla 7, constituye el fundamento teórico del método.

7. Comparación con métodos deterministas

7.1. Descripción

En dimensión baja, los métodos deterministas clásicos presentan una convergencia notablemente más rápida que Monte Carlo. La regla del rectángulo, por ejemplo, alcanza un orden $\mathcal{O}(n^{-1})$ o superior, frente al orden $\mathcal{O}(n^{-1/2})$ del método Monte Carlo. En este apartado se comparan ambos métodos de forma empírica.

7.2. Resultados

Se evalúa la integral de $f(x) = e^x$ en $[0, 1]$ mediante ambos métodos para distintos valores de n . La Tabla 9 recoge los errores y la Figura 6 los representa en escala log-log junto con las rectas de referencia teóricas.

Tabla 9. Errores cometidos por Monte Carlo y por la regla del rectángulo para la integral de e^x en $[0, 1]$.

n	Error MC	Error regla del rectángulo
10	0,115407	0,084482
50	0,055174	0,017126
100	0,036340	0,008577
500	0,015968	0,001718
1 000	0,009616	0,000859
5 000	0,006029	0,000172
10 000	0,003967	0,000086
50 000	0,001767	0,000017
100 000	0,001254	0,000009
500 000	0,000528	0,000002




Figura 6. Comparación log-log de Monte Carlo uniforme y regla del rectángulo para $f(x) = e^x$, junto con las referencias teóricas $\mathcal{O}(n^{-1/2})$ y $\mathcal{O}(n^{-1})$.

7.3. Observaciones

La regla del rectángulo, con orden $\mathcal{O}(n^{-1})$, converge más rápidamente que Monte Carlo, cuyo orden es $\mathcal{O}(n^{-1/2})$. En problemas unidimensionales los métodos deterministas son, por tanto, claramente superiores. Sin embargo, como se verá en la siguiente sección, al aumentar la dimensión Monte Carlo conserva su orden de convergencia mientras que los métodos deterministas sufren la *maldición de la dimensionalidad*: al crecer la dimensión, el volumen del espacio aumenta exponencialmente y se requieren exponencialmente más puntos para mantener la misma densidad de muestreo.

8. Integración en dimensión superior

8.1. Descripción

El método Monte Carlo se extiende de manera natural a integrales múltiples: basta con generar puntos uniformes en el dominio y promediar los valores de la función. En baja dimensión, los métodos deterministas basados en mallas siguen siendo más precisos, pero su coste computacional crece exponencialmente con la dimensión (maldición de la dimensionalidad). Por ello, en problemas de alta dimensión Monte Carlo resulta especialmente competitivo.

Si $x_1, \dots, x_n$ son puntos generados uniformemente en un dominio $D \subset \mathbb{R}^d$, la aproximación es

$$\int_D f(x) dx \approx \text{vol}(D) \cdot \frac{1}{n} \sum_{i=1}^n f(x_i), \quad (7)$$

donde $\text{vol}(D)$ denota el volumen del dominio. Esta formulación se extiende trivialmente a cualquier dimensión.

8.2. Monte Carlo en dos dimensiones

Se aplica el método a tres funciones de prueba en dominios rectangulares. La Tabla 10 recoge las aproximaciones obtenidas junto con los errores medios.

Tabla 10. Monte Carlo uniforme sobre funciones bidimensionales en dominios rectangulares.

Función	Dominio	Aprox. MC	Valor exacto	Error medio
$x^2 + y^2$	$[0, 1] \times [0, 1]$	0,666764	0,666667	0,001184
$\text{sen}(x) \cos(y)$	$[0, \pi] \times [0, \pi/2]$	1,998921	2,000000	0,003386
$e^{-(x^2+y^2)}$	$[-1, 1] \times [-1, 1]$	2,230996	2,230985	0,001728




Figura 7. Convergencia del método Monte Carlo en 2D para $f(x, y) = x^2 + y^2$ en $[0, 1] \times [0, 1]$. La pendiente en log-log se mantiene próxima a $\mathcal{O}(n^{-1/2})$.

Con esto se comprueba que el orden de convergencia se mantiene en $\mathcal{O}(n^{-1/2})$, igual que en una dimensión. Esta invariancia frente a la dimensión es una de las mayores ventajas del método.

El método se extiende además a dominios no rectangulares mediante un criterio de aceptación. Se consideran dos funciones sobre el disco unitario: $f(x, y) = 1$ y $f(x, y) = x^2 + y^2$. Los puntos se generan uniformemente en $[-1, 1] \times [-1, 1]$ y se aceptan únicamente aquellos que satisfacen $x^2 + y^2 \leq 1$. Con $n = 200\,000$ puntos y promediando 30 aproximaciones, se obtienen los resultados de la Tabla 11.

Tabla 11. Monte Carlo con aceptación–rechazo sobre el disco unitario ($n = 200\,000$, 30 repeticiones).

Función	Aprox. MC	Valor exacto	Error
$f = 1$ (área del disco)	3,141593	3,141593	0,000000
$f = x^2 + y^2$	1,570186	1,570796	0,000610




Figura 8. Método de aceptación–rechazo sobre el disco de radio 1: puntos aceptados (azul) y rechazados (rojo).

La proporción de puntos aceptados es 0,7854, próxima al valor teórico $\pi/4$, lo que proporciona la estimación $\pi \approx 3,1400$.

8.3. Comparación con métodos deterministas en 2D

Se aproxima la misma integral mediante la regla del rectángulo en 2D, evaluando f en los nodos de una malla $m \times m$ sobre $[-r, r]^2$ y sumando únicamente los puntos interiores al disco. Las Tablas 12 y 13 recogen los resultados.

Tabla 12. Regla del rectángulo 2D sobre el disco unitario, con m nodos por dirección.

m	Evaluaciones	Aproximación	Error
10	80	1,625600	0,054804
20	316	1,588600	0,017804
50	1 976	1,590712	0,019916
100	7 860	1,573180	0,002384
200	31 428	1,572002	0,001206
500	196 364	1,571027	0,000231

Tabla 13. Monte Carlo 2D sobre el disco unitario (media de 30 ejecuciones).

n	Error medio
100	0,063620
400	0,038838
2 500	0,015168
10 000	0,008859
40 000	0,004325
250 000	0,001738




Figura 9. Comparación del error en función del número de evaluaciones para Monte Carlo y regla del rectángulo 2D sobre el disco unidad.

Monte Carlo mantiene su orden de convergencia $O(n^{-1/2})$ en 2D, mientras que la regla del rectángulo converge más lentamente que en 1D, acercándose al comportamiento de Monte Carlo. Este es el primer indicio de la ventaja comparativa que presenta el método al aumentar la dimensión.

8.4. Dimensión alta

Se aproxima ahora, mediante Monte Carlo, la integral

$$\int_{[-1,1]^d} \frac{1}{1 + \|x\|_2^8} dx, \quad \|x\|_2 = \sqrt{x_1^2 + x_2^2 + \cdots + x_d^2}, \quad (8)$$

para varios valores de d , promediando 20 aproximaciones con $n = 500\,000$. Los resultados se muestran en la Tabla 14.

Tabla 14. Aproximación Monte Carlo de la integral en dimensión d con $n = 500\,000$.

d	Aproximación MC	Desviación típica
1	1,849432	0,000352
2	2,983775	0,001559
3	4,352458	0,002722
5	7,638415	0,013092
10	22,649330	0,082256

El valor de la integral crece con d porque el volumen del hipercubo es 2^d y, en dimensión alta, la función tiende a 1 lejos del origen. Al evaluar el coste computacional de ambos métodos en función de d se obtienen los resultados de la Tabla 15.

Tabla 15. Coste computacional comparado: Monte Carlo frente a una malla regular con $m = 10$ nodos por dirección.

d	n Monte Carlo	Tiempo MC (s)	n malla = m^d	Tiempo malla (s)
1	100 000	0,0038	10	0,0001
2	100 000	0,0081	100	0,0002
3	100 000	0,0107	1 000	0,0003
5	100 000	0,0134	100 000	0,0087
10	100 000	0,0184	10 000 000 000	N/A




Figura 10. Maldición de la dimensionalidad: evolución del número de evaluaciones (izquierda) y del tiempo de cómputo (derecha) frente a la dimensión, para Monte Carlo y malla regular.

La malla regular requiere m^d evaluaciones, lo que implica un crecimiento exponencial en d . Para $m = 10$ y $d = 10$ se necesitarían del orden de 10^{10} evaluaciones. En cambio, Monte Carlo utiliza n evaluaciones con un error $\mathcal{O}(n^{-1/2})$, independiente de la dimensión. En dimensión alta, Monte Carlo es la única opción computacionalmente viable, lo que explica su papel central en *Machine Learning* y simulación.

9. Aplicación: valoración de opciones financieras

9.1. Introducción

Como aplicación práctica de los métodos estudiados, se aborda la valoración de una *opción call europea* mediante Monte Carlo. Una opción *call* otorga a su tenedor el derecho de adquirir un activo subyacente a un precio pactado K (*strike*) en una fecha futura T . Bajo el modelo de Black–Scholes, el precio justo de la opción es el valor esperado del pago descontado al tipo libre de riesgo r :

$$C = e^{-rT} \mathbb{E}[\max(S_T - K, 0)]. \quad (9)$$

Esta expresión es, en esencia, una integral que puede aproximarse por Monte Carlo. Se asume que el precio del activo en el vencimiento sigue un movimiento browniano geométrico. Bajo la medida riesgo-neutral,

$$S_T = S_0 \exp\left(\left(r - \frac{\sigma^2}{2}\right)T + \sigma\sqrt{T}Z\right), \quad Z \sim \mathcal{N}(0, 1). \quad (10)$$

Los parámetros utilizados son $S_0 = 100 \text{ €}$, $K = 105 \text{ €}$, $r = 5 \%$, $\sigma = 20 \%$ y $T = 1$ año.

9.2. Estimación Monte Carlo y validación

Se generan $n = 100\,000$ muestras de $Z \sim \mathcal{N}(0, 1)$, se calcula el precio al vencimiento S_T para cada una de ellas y se estima el precio de la opción como la media descontada de los pagos. El resultado se compara con la fórmula cerrada de Black–Scholes, que proporciona el valor exacto bajo el mismo modelo.

Tabla 16. Resultados de la valoración de la opción call europea por Monte Carlo y su contraste con la fórmula de Black–Scholes.

Magnitud	Valor
Precio Monte Carlo	8,0062 €
Intervalo de confianza al 95 %	$\pm 0,0864 \text{ €}$
Precio Black–Scholes	8,0214 €
Error absoluto	0,0151 €

El error absoluto de $0,0151 \text{ €}$ está contenido dentro del intervalo de confianza al 95 % de $\pm 0,0864 \text{ €}$, lo que confirma que la estimación es estadísticamente correcta.

9.3. Convergencia

Se repite la estimación para valores de n entre 10^2 y 10^6 , representando el error en escala log–log frente a la recta de referencia de pendiente $-1/2$.




Figura 11. Convergencia Monte Carlo en la valoración de la opción call europea: error absoluto frente al número de simulaciones, comparado con la referencia teórica $\mathcal{O}(n^{-1/2})$.

La gráfica confirma la tasa de convergencia $\mathcal{O}(n^{-1/2})$ característica de Monte Carlo, en plena concordancia con los resultados de la sección 4.

9.4. Reducción de varianza mediante *importance sampling*

Cuando la opción está muy *fuera del dinero* ($K \gg S_0$), la mayor parte de las simulaciones producen un pago nulo, lo que se traduce en un estimador de varianza elevada. Para mitigarlo se aplica *importance sampling* con una distribución propuesta normal desplazada hacia el *strike*, concentrando las muestras en la región relevante.

Empleando como densidad propuesta una $\mathcal{N}(\mu_{\text{prop}}, \sigma_{\text{prop}}^2)$ centrada en el punto donde la opción comienza a tener valor, se obtienen los resultados de la Tabla 17.

Tabla 17. Comparación entre Monte Carlo uniforme e *importance sampling* en la valoración de la opción.

Método	Prima estimada	Varianza relativa
Monte Carlo uniforme	8,0062 €	1,66
<i>Importance sampling</i>	8,0539 €	1,19

La varianza relativa se reduce de 1,66 a 1,19, lo que supone una mejora próxima al 28 %. El efecto confirma la utilidad del método, aunque en este caso la opción no esté especialmente fuera del dinero; la mejora sería considerablemente mayor en configuraciones más extremas.

9.5. Observaciones

Si bien en este caso existe una fórmula cerrada (Black–Scholes) con la que contrastar los resultados, el enfoque Monte Carlo cobra especial relevancia en opciones más complejas, como las asiáticas, de barrera o sobre cestas de activos, en las que no se dispone de solución analítica. En tales contextos, Monte Carlo constituye prácticamente la única metodología viable, lo que justifica su amplio uso en la industria financiera.

10. Conclusiones

A lo largo de este proyecto se han estudiado y comparado distintos métodos tipo Monte Carlo para la aproximación de integrales, analizando su variabilidad, su convergencia y su eficiencia frente a los métodos deterministas clásicos.

El método Monte Carlo básico, basado en interpretar la integral como una esperanza y estimarla mediante una media muestral, produce resultados correctos pero con una convergencia lenta, de orden $\mathcal{O}(n^{-1/2})$. Esto implica que reducir el error a la mitad requiere cuadruplicar el número de muestras, lo que lo hace poco competitivo en baja dimensión frente a reglas deterministas como la del rectángulo, cuyo orden es $\mathcal{O}(n^{-1})$, tal y como se ha verificado experimentalmente en las secciones 4 y 7.

La verdadera ventaja de Monte Carlo emerge, sin embargo, en dimensión alta. Mientras que los métodos deterministas basados en mallas requieren un número de evaluaciones que crece exponencialmente con la dimensión (m^d), Monte Carlo mantiene su orden de convergencia independientemente de la misma. Este fenómeno, conocido como *maldición de la dimensionalidad*, convierte a los métodos deterministas en inviables a partir de cierta dimensión, como ha quedado de manifiesto en la sección 8.

El método de *importance sampling* ha demostrado ser una mejora significativa del Monte Carlo básico en situaciones en las que la función presenta regiones de alta contribución muy localizadas: picos estrechos, oscilaciones pronunciadas o eventos de baja probabilidad. En la sección 6 se ha comprobado que elegir una densidad propuesta adaptada a la forma de la función reduce notablemente la varianza del estimador, llegando incluso al caso ideal de varianza nula cuando $\rho \propto f$.

Finalmente, la aplicación financiera desarrollada en la sección 9 ilustra la utilidad práctica de Monte Carlo en un contexto real. La valoración de una opción *call* europea mediante simulación ha reproducido con precisión el precio teórico de Black–Scholes, confirmando tanto la corrección del método como su tasa de convergencia teórica. La aplicación conjunta de *importance sampling* ha permitido además reducir la varianza del estimador en torno a un 28 %, poniendo de manifiesto que la combinación de ambas técnicas resulta especialmente relevante cuando la opción está fuera del dinero.

En conjunto, el proyecto ilustra el papel dual de los métodos Monte Carlo: relativamente modestos en baja dimensión, donde los métodos clásicos resultan superiores, pero imprescindibles en dimensión alta y en problemas complejos, donde son con frecuencia la única herramienta disponible. Este es precisamente el motivo de su protagonismo en campos como el aprendizaje automático, la física computacional y la ingeniería financiera.